

Relatório de Resultados do Experimento

Análise Exploratória de Dados — Preços de Combustíveis Automotivos (Base 2024.01, Arapiraca/AL e demais municípios)

Versão 2 — atualizado conforme as melhorias aplicadas ao script analise_p.py

1. Introdução

Este relatório apresenta os resultados da análise exploratória realizada sobre o conjunto de dados de preços semestrais de combustíveis automotivos (2024.01). O objetivo é identificar os tipos de variáveis presentes, calcular medidas descritivas de preço por tipo de combustível, avaliar a distribuição dos preços e comparar bandeiras revendedoras, além de responder a um conjunto de questões de avaliação sobre os resultados obtidos.

A base de dados original possui 49.998 registros e 16 colunas, cobrindo informações de localização (região, estado, município, endereço), identificação da revenda (CNPJ, nome, bandeira), o produto comercializado, a data de coleta e os valores de venda e de compra.

Esta versão do relatório reflete as melhorias mais recentes feitas no script de análise (analise_p.py): o cálculo de outliers passou a ser feito por tipo de produto (em vez de um único limite global) e os gráficos gerados passaram a ser salvos automaticamente em disco, na pasta imagens/, além de exibidos em tela. Os números e conclusões abaixo já incorporavam o critério de IQR por produto; a mudança no código apenas tornou esse comportamento explícito e reproduzível a partir de agora.

2. Metodologia e Etapas Realizadas

a) Tipos de variáveis presentes no dataset

Cada coluna foi classificada quanto à sua natureza estatística. A coluna "Valor de Compra" veio totalmente vazia (100% dos registros nulos) e foi removida do conjunto tratado. A coluna "Data da Coleta" foi tratada separadamente como variável temporal, por não ser adequadamente descrita nem como qualitativa nem como quantitativa comum.

Coluna	Tipo de variável	Observação
Região - Sigla	Qualitativa (nominal)	Categoria geográfica
Estado - Sigla	Qualitativa (nominal)	Categoria geográfica
Município	Qualitativa (nominal)	Categoria geográfica
Revenda	Qualitativa (nominal)	Nome da empresa
CNPJ da Revenda	Qualitativa (nominal)	Identificador — não é quantidade
Nome da Rua / Nº / Bairro / CEP	Qualitativa (nominal)	Endereço
Produto	Qualitativa (nominal)	Tipo de combustível
Data da Coleta	Temporal	Convertida para datetime
Valor de Venda	Quantitativa (contínua)	Variável de interesse principal
Valor de Compra	— (removida)	100% dos valores ausentes
Unidade de Medida	Qualitativa (nominal)	Ex.: R\$/litro
Bandeira	Qualitativa (nominal)	Distribuidora/rede

b) Medidas descritivas do preço de venda por tipo de combustível

Após a limpeza (remoção de espaços, conversão de vírgula decimal e checagem de duplicidades), foram calculadas as medidas de tendência central e dispersão do preço de venda para cada tipo de produto:

Produto	n	Média	Mediana	Desvio-padrão	Variância	Mín.	Máx.
Etanol	10.838	R\$ 3,71	R\$ 3,69	0,56	0,31	R\$ 2,64	R\$ 6,60
GNV	1.019	R\$ 4,74	R\$ 4,69	0,48	0,23	R\$ 3,54	R\$ 6,69
Gasolina	12.798	R\$ 5,62	R\$ 5,59	0,40	0,16	R\$ 4,58	R\$ 7,99
Gasolina Aditivada	10.165	R\$ 5,81	R\$ 5,79	0,40	0,16	R\$ 4,75	R\$ 8,69
Diesel	5.829	R\$ 5,93	R\$ 5,89	0,38	0,15	R\$ 4,69	R\$ 8,19
Diesel S10	9.349	R\$ 6,01	R\$ 5,99	0,39	0,15	R\$ 5,09	R\$ 8,89

O etanol é o combustível mais barato em média (R\$ 3,71) e também o de maior variabilidade relativa (desvio-padrão 0,56), refletindo diferenças regionais de produção e tributação. Os diesel (comum e S10) apresentam os maiores preços médios, com dispersão relativamente baixa (desvio-padrão $\approx 0,38-0,39$).

c) Distribuição dos preços

A figura abaixo — gerada e salva automaticamente pelo script em `imagens/boxplot_precos.png` — combina o boxplot dos preços por tipo de produto e o histograma da distribuição geral em uma única imagem:




Figura 1 — Boxplot por produto e histograma geral dos preços de venda (`imagens/boxplot_precos.png`).

A distribuição geral é bimodal: um agrupamento concentrado entre R\$ 3,00 e R\$ 4,50 (dominado pelo etanol e GNV) e outro, mais alto e com maior volume, entre R\$ 5,00 e R\$ 6,50 (gasolina, gasolina aditivada e diesel) — bimodalidade esperada, já que estamos combinando produtos com faixas de preço estruturalmente diferentes.

O boxplot por produto evidencia diversos pontos fora dos limites do intervalo interquartil (outliers) em praticamente todos os combustíveis, sendo mais numerosos no Diesel S10, Gasolina Aditivada e Diesel. Esses limites são calculados separadamente para cada produto (ver seção "Atualizações realizadas no script"), o que evita comparar, por exemplo, o preço do etanol com o intervalo típico do diesel.

d) Comparação dos preços médios entre bandeiras

A imagem abaixo também é gerada e salva automaticamente pelo script, em imagens/medias_por_bandeira.png:




Figura 2 — Preço médio de venda por bandeira, todos os combustíveis (imagens/medias_por_bandeira.png).

Considerando todos os combustíveis, a bandeira EQUADOR apresenta o maior preço médio (R\$ 6,46), seguida por SUL COMBUSTÍVEIS (R\$ 6,24) e DIBRAPE (R\$ 6,05). No extremo oposto, FEDERAL ENERGIA (R\$ 4,80), D'MAIS (R\$ 5,00) e TDC DISTRIBUIDORA (R\$ 5,04) registram os menores preços médios. Bandeiras de grande capilaridade nacional, como VIBRA (R\$ 5,44), IPIRANGA (R\$ 5,44) e RAIZEN (R\$ 5,30), ficam na faixa intermediária, puxando a média geral para baixo por concentrarem a maior parte do volume de registros.

Para responder às perguntas 3 e 4 da avaliação (variabilidade e outliers de gasolina por bandeira), foi feito um recorte complementar — focado apenas no produto Gasolina — que não faz parte da saída padrão do script, mas usa a mesma lógica de limpeza e cálculo:




Figura 3 — Boxplot do preço da gasolina por bandeira (análise complementar).

e) Atualizações realizadas no script

Desde a primeira versão deste relatório, o script `analise_p.py` recebeu duas melhorias relevantes para a qualidade e a reprodutibilidade da análise:

- IQR por produto: a função `detectar_outliers()` agora calcula Q1 e Q3 separadamente para cada tipo de produto (`groupby(produto)`), em vez de um único limite sobre toda a base. Isso evita que a diferença natural de faixa de preço entre combustíveis (ex.: etanol ~R\$ 3,71 vs. diesel ~R\$ 6,01) gere falsos outliers. O total de 1.395 outliers apresentado na seção de avaliação já reflete esse critério.
- Gráficos salvos automaticamente: as funções `plotar_boxplot_e_histograma()` e `plotar_medias_por_bandeira()` agora salvam suas figuras em `imagens/boxplot_precos.png` e `imagens/medias_por_bandeira.png` (300 dpi), além de exibi-las em tela. A pasta `imagens/` é criada automaticamente pelo script, caso ainda não exista.
- Correção de figuras sobrepostas: ao salvar os gráficos em disco, identificamos que a figura do `boxplot/histograma` não era fechada (`plt.close()`) antes de gerar o gráfico de bandeiras, fazendo com que o `matplotlib` reaproveitasse a mesma figura e sobrepujasse os dois gráficos em um único arquivo corrompido. Ambas as funções de plotagem agora criam sua própria figura explicitamente e a fecham após salvar, garantindo que cada imagem em `imagens/` contenha exatamente o gráfico pretendido.

3. Avaliando os Resultados

1) Há registros duplicados? Quantos foram removidos?

Não foram encontrados registros duplicados. Duas verificações foram aplicadas: (i) duplicidade de linha inteira (todas as colunas idênticas) e (ii) duplicidade pela chave de negócio CNPJ da Revenda + Produto + Data da Coleta, que identificaria uma mesma revenda reportando o mesmo produto duas vezes no mesmo dia. Em ambos os casos o resultado foi 0 duplicatas — as 49.998 linhas originais permaneceram todas após a etapa de checagem de duplicidade.

2) Qual é a faixa de preço da gasolina no município de Arapiraca?

Em Arapiraca/AL, considerando apenas o produto "GASOLINA" (comum, sem a aditivada), foram encontrados 44 registros, com preços variando de R\$ 5,35 a R\$ 6,69 (amplitude de R\$ 1,34) e média de R\$ 5,56. Se considerarmos também a "Gasolina Aditivada" no mesmo cálculo, o total sobe para 77 registros, mas a faixa mín./máx. permanece a mesma (R\$ 5,35 a R\$ 6,69), pois os extremos de preço já pertencem à gasolina comum.

3) Qual bandeira apresenta maior variabilidade de preços para gasolina?

Entre as bandeiras com pelo menos 5 registros de gasolina (para evitar distorções por amostras muito pequenas), a ATEM'S apresenta a maior variabilidade, com desvio-padrão de R\$ 0,73 (variância 0,53) sobre uma média de R\$ 6,24. Em seguida aparece a EQUADOR, com desvio-padrão de R\$ 0,51. As grandes bandeiras nacionais (VIBRA, IPIRANGA, BRANCA, RAIZEN) têm variabilidade bem menor (desvio-padrão entre R\$ 0,31 e R\$ 0,41), compatível com sua rede mais padronizada e homogênea de preços.

4) Existem outliers claros no boxplot? Qual bandeira tem os maiores desvios?

Sim. O boxplot por produto (Figura 1) exibe um número expressivo de pontos fora dos limites do intervalo interquartil, já calculado por produto (regra de $1,5 \times \text{IQR}$): ao todo 1.395 outliers, distribuídos entre Diesel S10 (353), Gasolina Aditivada (347), Diesel (295), Gasolina (208), Etanol (152) e GNV (40).

Ao restringir a análise à gasolina e cruzar os outliers com a bandeira (Figura 3), dois recortes se destacam: em número absoluto, a VIBRA concentra o maior número de pontos fora da faixa (87 registros), mas isso reflete principalmente seu grande volume de amostras (2.685 registros de gasolina). Em termos proporcionais — e coerente com o resultado da pergunta anterior — a ATEM'S tem o maior desvio relativo: 26,8% de suas observações de gasolina (15 de 56) caem fora do intervalo interquartil, contra apenas 3,2% da VIBRA e 1,0% da BRANCA. Portanto, a ATEM'S é a bandeira com os maiores desvios de preço para gasolina, tanto pelo desvio-padrão quanto pela proporção de outliers.

5) Qual CNPJ tem o maior valor médio de venda de combustível?

O CNPJ 01.777.592/0001-15, da revenda SUPER POSTO FORTALEZA LTDA, apresenta o maior valor médio de venda entre todos os combustíveis, R\$ 7,84 (6 registros). Na sequência aparecem LUBRAS DISTRIBUIDORA LTDA (10.406.630/0001-14, média R\$ 7,76, 12 registros) e A. M. DE FARIAS - EPP (84.455.633/0003-46, média R\$ 7,72, 3 registros). Esses valores elevados refletem principalmente registros de Diesel S10 e Gasolina Aditivada, que são estruturalmente os produtos mais caros da base.

4. Texto Conclusivo

A análise exploratória mostrou uma base de dados consistente e sem duplicidades, exigindo apenas ajustes de formatação (conversão de texto para número, tratamento de datas e remoção de uma coluna integralmente vazia). O preço de venda varia de forma esperada conforme o tipo de combustível — etanol mais barato e mais disperso, diesel mais caro e mais estável — e a distribuição geral dos preços é bimodal justamente por combinar produtos de faixas de preço distintas.

Entre bandeiras, observam-se diferenças relevantes tanto de preço médio quanto de variabilidade: bandeiras menores e de menor volume amostral (como ATEM'S e EQUADOR) tendem a apresentar maior dispersão e maior proporção de outliers, possivelmente pela menor padronização de rede e pela sensibilidade a poucos postos com preços atípicos, enquanto as grandes bandeiras nacionais mostram preços mais uniformes. No recorte municipal de Arapiraca, os preços de gasolina ficaram concentrados numa faixa relativamente estreita (R\$ 5,35 a R\$ 6,69), compatível com o observado para o produto na base como um todo.

Em conjunto, os resultados reforçam a importância de segmentar a análise por tipo de produto (e não tratar o preço de venda como uma única distribuição agregada) e de considerar o tamanho da amostra ao comparar variabilidade entre bandeiras, já que bandeiras com poucos registros podem parecer mais ou menos variáveis apenas por efeito de amostragem. A atualização do script para calcular o IQR por produto e salvar os gráficos automaticamente torna essa análise mais precisa e mais fácil de reproduzir em execuções futuras.